팀 14(def) 팀지도교수님 면담보고서

팀명	**def (team 14)**
프로젝트명	로컬 환경에서의 Agentic AI 병목 분석 및 성능 최적화: Apple silicon 온디바이스를 중심으로
지도교수	심재형 교수님
팀원	서혜원, 신은서, 이재린

주제

로컬(Mac mini, Mac studio 등 Apple Silicon 환경)에서 Agent AI를 실행했을 때, 발생하는 bottleneck들을 파악하고 개선할 점을 파악하여 최적화 하는 것을 큰 주제로 정하고, 교수님과의 면담을 진행하였습니다.

교수님 면담 내용

> 학부생 질문은 'Q)' 뒤에, 교수님 의견은 '교수님 의견)' 뒤에 작성하였습니다.

Q) benchmark 성능 최적화가 연구의 진행방향인지 실질적인 시스템 구현이 진행방향인지 확신이 안감.

- 교수님 의견) 실질적인 system sw stack을 건들여서 benchmark 최적화를 이루어내는 것이 최종 목표라고 제안하셨습니다.

Q) 맥미니같은 작은 device에서도 잘 돌아갈 수 있도록 최적화를 하는건데, 교수님의 첫번째 논문에서의 제시한 아이디어는 KV Cache의 줄이기(SideQuest로 빼돌려서 필요없는 것을 판단해서 삭제)인데 KV cache에 관해서 더 깊게 파고들지 아니면 다른 Bottleneck들을 더 탐구해보는게 좋을지 판단하기 어려움.

- 교수님 의견) KV-Cache의 compression을 적용하면 agentic AI의 의미가 희석됨. 또한 KV-Cache에 관련한 연구는 치열하게 이루어지고 있어 학부생으로서 성과를 내기 어려움. 따라서 cache 단에서의 bottleneck에 한정짓지 말고 메모리 대역폭, agent 루프에서의 지연, context 관리 등 발견되지 않은 문제점을 찾는것에 목표를 두자고 제안하셨습니다.

Q) Apple silicon 환경에서는 선행된 연구가 거의 없어서 논문을 구현하여 문제점을 탐구하기가 어려움.

- 교수님 의견) 직접 Agent AI(open claw)를 로컬에서 실행해보며, 위에서 언급했던 bottleneck을 찾는 것으로 시작하라고 제안해 주셨습니다.

구체적 방향

- Agentic AI의 동작 방식을 이해하기 위한 논문 읽기 : 어떻게 동작되는지를 우선 파악해야 직접 돌려봤을 때 문제점을 파악할 수 있음.
  <선정한 선행 연구 논문 리스트>
  - SideQuest: Model-Driven KV Cache Management for Long-Horizon Agentic Reasoning
  - ReAct: Synergizing Reasoning and Acting in Language Models
  - Agentic AI: Autonomous Intelligence for Complex Goals—A Comprehensive Survey
- Mac Studio 로컬에서 Open claw 직접 실행해보며 앞에서 언급한 bottleneck 파악하기